

Pembangunan *Data Warehouse* dengan Integrasi ETL dan ELT untuk Analisis *Business Intelligence* pada Kasus Mangkir Pasien

1st Maleakhi Nymmo Augustus
Teknik Komputer
Telkom University
Bandung, Indonesia
maleakhinymmo013@gmail.com

2nd Angel Metanosa A., S.Kom, M.Kom
Teknik Komputer
Telkom University
Bandung, Indonesia
angelmentanosa@telkomuniversity.ac.id

Abstrak—*Fenomena ketidakhadiran pasien (no-show) pada jadwal janji temu medis menimbulkan inefisiensi operasional yang signifikan pada fasilitas kesehatan. Untuk menggali pola penyebab ketidakhadiran tersebut, diperlukan dukungan arsitektur pengolahan Big Data yang andal. Penelitian ini bertujuan untuk mengimplementasikan dan mengevaluasi dua pendekatan data pipeline, yaitu Extract, Transform, Load (ETL) dan Extract, Load, Transform (ELT), dalam membangun sebuah Data Warehouse. Dataset yang digunakan bersumber dari "Medical Appointment No Shows" yang memuat lebih dari 100.000 rekam medis dengan variabel demografi, waktu, spasial, dan riwayat komorbiditas. Pada jalur ETL, proses transformasi tingkat lanjut seperti pembersihan data, standarisasi, dan feature engineering dieksekusi di luar basis data menggunakan pustaka Python (Pandas) sebelum dimuat ke dalam pemodelan Star Schema di SQLite. Sebaliknya, pada jalur ELT, data mentah diekstraksi dan langsung dimuat ke dalam warehouse, di mana proses transformasi dilakukan secara internal menggunakan bahasa SQL dan Data Analysis Expressions (DAX) melalui Microsoft Power BI. Hasil penelitian ini menyajikan analisis komparatif performa kedua arsitektur berdasarkan kompleksitas desain dan konsistensi data, yang bermuara pada sebuah dashboard analitik interaktif. Dashboard ini memfasilitasi pengambilan keputusan manajerial dengan memvisualisasikan faktor risiko no-show berdasarkan sebaran wilayah dan kondisi penyakit bawaan pasien.*

Kata Kunci—*Big Data Pipeline, Data Warehouse, ETL, ELT, Analisis Komparatif, No-Show, Business Intelligence*

I. PENDAHULUAN

Manajemen pelayanan fasilitas kesehatan yang optimal sangat bergantung pada kedisiplinan jadwal. Salah satu kendala operasional yang sering dihadapi adalah tingginya tingkat ketidakhadiran pasien pada janji temu medis yang telah disepakati (no-show). Ketidakhadiran ini mengakibatkan kerugian finansial, terbuangnya waktu tenaga medis, serta hilangnya kesempatan bagi pasien lain yang membutuhkan penanganan darurat. Untuk menekan angka no-show, pihak manajemen memerlukan wawasan analitik yang mendalam mengenai faktor-faktor risiko pasien, seperti pola waktu pendaftaran, lokasi tempat tinggal, hingga riwayat penyakit bawaan (komorbiditas).

Kebutuhan akan wawasan berbasis data (data-driven) tersebut menuntut adanya sistem pengolahan data berskala besar yang terstruktur. Dalam disiplin Big Data Engineering, pembangunan Data Warehouse merupakan langkah esensial untuk memusatkan dan mengintegrasikan berbagai sumber data. Secara arsitektural, terdapat dua perdebatan paradigma utama dalam merancang pipeline aliran data menuju

warehouse, yaitu pendekatan Extract, Transform, Load (ETL) tradisional dan pendekatan Extract, Load, Transform (ELT) modern.

Pendekatan ETL memproses dan membersihkan data di dalam staging area (umumnya menggunakan bahasa pemrograman seperti Python) sebelum data tersebut masuk ke dalam basis data analitik. Di sisi lain, pendekatan ELT memanfaatkan kapasitas komputasi dari sistem Data Warehouse atau perangkat Business Intelligence itu sendiri untuk melakukan transformasi data setelah data mentah berhasil dimuat. Mengingat kompleksitas pemrosesan data medis yang melibatkan penanganan anomali, nilai kosong (missing value), dan rekayasa fitur (feature engineering), pemilihan arsitektur pipeline yang tepat menjadi sangat krusial.

Penelitian ini bertujuan untuk melakukan studi komparatif secara komprehensif antara implementasi pipeline ETL dan ELT menggunakan studi kasus nyata pada data ketidakhadiran pasien. Proses pengolahan data dirancang menggunakan model Star Schema untuk mengoptimalkan efisiensi kueri analitik. Hasil akhir dari pemrosesan data pada kedua jalur arsitektur ini divisualisasikan dalam bentuk dashboard analitik interaktif menggunakan Power BI. Melalui eksperimen implementasi ini, perbedaan karakteristik, efisiensi desain, dan pendekatan transformasi antara ETL dan ELT dapat dievaluasi secara objektif, sehingga memberikan rekomendasi teknis yang relevan bagi pengembangan analitik layanan kesehatan di masa depan.

II. METODOLOGI PENELITIAN

A. Arsitektur Sistem Secara Keseluruhan

"Arsitektur pengolahan data dirancang untuk memetakan seluruh aliran data mulai dari tahap akuisisi sumber data hingga penyajian informasi akhir. Pemetaan visual dari alur sistem *dual pipeline* ini dapat dilihat pada Fig. 1. Komponen utama dalam arsitektur ini meliputi:




Fig. 1. Diagram Arsitektur Sistem Dual-Pipeline ETL dan ELT.

1. **Sumber Data (Data Sources):** Terdiri dari minimal dua sumber data mentah dengan format berbeda, yakni file data utama rekam medis pasien (format CSV) dan data pendukung wilayah spasial/kontekstual (format JSON atau database lokal).
2. **Data Lake / Staging Area:** Berfungsi sebagai repositori penyimpanan data mentah yang diisolasi tanpa proses modifikasi awal untuk jalur ETL.
3. **Pipeline ETL:** Jalur pemrosesan berbasis Python (Pandas) untuk melakukan transformasi berat (pembersihan, penanganan outlier, standarisasi, rekayasa fitur, dan validasi kualitas data) sebelum dimuat ke target.
4. **Pipeline ELT:** Jalur pemrosesan di mana data mentah langsung dimuat ke area penampungan warehouse, lalu ditransformasikan menggunakan kueri SQL internal dan fungsionalitas mesin analitik Power BI.
5. **Data Warehouse:** Basis data relasional berbasis SQLite yang dimodelkan menggunakan pendekatan Star Schema untuk efisiensi penyimpanan dan performa kueri.
6. **Dashboard Analitik:** Antarmuka visual akhir menggunakan Power BI yang terhubung secara langsung (Direct/Live Connection) ke Data Warehouse.

B. Implementasi Pipeline ETL (Extract, Transform, Load)

Pipeline ETL dirancang dengan memusatkan seluruh beban kerja transformasi data di luar lingkungan Data Warehouse (client-side processing).

1. Tahap *Extract*

Proses ekstraksi data dilakukan secara terprogram menggunakan bahasa Python tanpa melibatkan manipulasi data. Dua fungsi utama diimplementasikan untuk mengamankan data dari masing-masing sumber ke dalam direktori lokal raw/

- `extract_etl_source1()`: Mengekstrak dataset utama janji temu medis pasien.
- `extract_etl_source2()`: Mengekstrak dataset sekunder terkait informasi kewilayahan/geografis (neighbourhood).

2. Tahap *Transform*

Tahap transformasi memegang bobot kompleksitas tertinggi dan dibagi menjadi beberapa sub-proses:

- **Data Cleaning:** Menghapus data ganda (*duplicate data*) berdasarkan ID janji temu (*appointment id*). Nilai yang hilang (*missing value*) ditangani menggunakan strategi imputasi yang sesuai dengan tipe data (misalnya nilai modus untuk kategorikal dan nilai median untuk numerik). Format tanggal dan waktu diseragamkan ke dalam standar ISO (YYYY-MM-DD). Nilai *outlier* pada kolom usia (Age) dideteksi dan dieliminasi menggunakan metode *Interquartile Range*

(IQR) dengan ambang batas bawah $Q_1 - 1.5 * IQR$

- **Standarisasi Data:** Penamaan seluruh kolom diubah secara otomatis menjadi format lowercase dan *snake_case*. Dua kolom numerik (seperti usia dan hari tunggu) dinormalisasi, serta dilakukan pengodean (*encoding*) pada fitur kategorikal. Konsistensi tipe data dipastikan secara ketat pada setiap kolom.
- **Data Enrichment dan Feature Engineering:** Data dari sumber utama dan sekunder digabungkan menggunakan operasi *merge* berdasarkan kunci relasi. Minimal lima fitur baru diciptakan, di antaranya: *lead_time_days* (selisih hari antara pendaftaran dan janji temu), *appointment_day* (nama hari), *appointment_month* (nama bulan), *age_group* (kategorisasi kelompok umur), dan *total_comorbidities* (agregasi jumlah penyakit bawaan yang diidap pasien).
- **Validasi Kualitas Data:** Sebelum disimpan ke Data Warehouse, data divalidasi melalui enam aturan kualitas: *uniqueness check* pada ID, *null check* pada kolom esensial, *range check* (misalnya usia harus > 0), *datatype consistency*, *referential integrity* antar tabel, dan pengecekan distribusi data untuk memastikan tidak ada anomali struktural.

3. Tahap *Load*

Data hasil transformasi dimuat ke dalam Data Warehouse SQLite dengan arsitektur Star Schema. Desain skema terdiri dari:

- Tabel Fakta (*fact_appointments*): Menyimpan metrik utama dan *Foreign Key*.
- Tabel Dimensi (*dim_patient* dan *dim_location*): Menyimpan data master profil pasien dan informasi geografis regional.

C. Implementasi Pipeline ETL (Extract, Transform, Load)

1. Tahap *Extract* dan *Load*

Dataset mentah dari kedua sumber diekstraksi tanpa melalui proses pembersihan atau rekayasa fitur apa pun di sisi Python. Data mentah tersebut langsung dimuat (*Load*) ke dalam repositori *Data Lake* atau tabel berstatus raw di dalam *Data Warehouse*. Dokumentasi metadata mencatat ukuran file dan struktur data asli apa adanya.

2. Tahap *Transform*

- **Pembersihan dan Penggabungan Data:** Operasi pembersihan data ganda, penanganan nilai kosong, dan penggabungan (*join/merge*) antar tabel mentah dieksekusi menggunakan kueri SQL internal *warehouse*.
- **Transformasi Tingkat Lanjut via Power BI:** Data yang telah berada di *warehouse*

ditarik ke dalam Power BI. Transformasi dilakukan secara dinamis di tingkat *BI Engine* menggunakan kombinasi rumus *Data Analysis Expressions* (DAX) untuk kalkulasi metrik analitik dan agregasi.

- **Teknik Unpivot untuk Analisis Komorbiditas:** Perbedaan paling mendasar dari jalur ETL adalah penerapan teknik *Unpivot* di dalam Power Query pada kolom-kolom penyakit bawaan (hipertension, diabetes, alcoholism, handicap). Kolom yang semula melebar ke samping (*wide format*) diubah strukturnya memanjang ke bawah (*long format*) menjadi sepasang atribut nama penyakit dan nilai indikatornya. Pendekatan ini memungkinkan visualisasi perbandingan metrik ketidakhadiran antar penyakit dapat disajikan secara sejajar dan dinamis dalam satu sumbu grafik tanpa mengubah struktur tabel fisik asli di basis data sumber.

D. Implementasi Pipeline ETL (Extract, Transform, Load)

Dashboard analitik dibangun menggunakan Microsoft Power BI yang terhubung langsung dengan skema basis data gudang data. Desain visual dirancang memenuhi standar aplikasi eksekutif modern dengan kriteria sebagai berikut:

1. **Key Performance Indicators (KPI):** Menyajikan metrik ringkasan utama seperti Total Pasien, Persentase Mangkir (% *No-Show*), dan Rata-rata Hari Tunggu (*Avg Hari Tunggu*) menggunakan visualisasi *Card*.
2. **Analisis Tren Waktu:** Menyajikan fluktuasi volume janji temu dan tingkat ketidakhadiran berbasis waktu menggunakan *Line Chart* kronologis.
3. **Distribusi dan Perbandingan Data:** Menggunakan komponen *Map* untuk visualisasi spasial sebaran pasien, *Bar Chart* untuk komposisi demografi, serta *Clustered Column Chart* untuk perbandingan performa kehadiran tiap penyakit bawaan.
4. **Filter Interaktif dan Conditional Formatting:** Menyediakan komponen *Slicer* pada *sidebar* untuk eksplorasi data berdasarkan wilayah (*Region*) dan kelompok usia (*Age Group*). Fitur *Conditional Formatting* berbasis parameter gradasi warna diimplementasikan secara dinamis pada kartu indikator klinis, sehingga warna teks akan otomatis berubah secara adaptif dari warna hijau (tingkat risiko aman) menjadi warna merah (tingkat risiko tinggi) ketika angka ketidakhadiran pasien melonjak saat filter diaktifkan.

III. HASIL DAN PEMBAHASAN

Bagian ini menguraikan hasil evaluasi dari implementasi kedua arsitektur *pipeline* data serta wawasan analitik yang diekstraksi dari *dashboard Business Intelligence*.

A. Analisis Komparatif Pendekatan ETL dan ELT

Berdasarkan eksperimen perancangan *pipeline* yang telah dieksekusi, terdapat beberapa temuan komparatif yang signifikan antara pendekatan ETL dan ELT:

1. **Kompleksitas Desain dan Fleksibilitas:** Pada *pipeline* ETL, seluruh aturan bisnis dan transformasi

data (seperti penanganan *outlier* dan standardisasi) di-*hardcode* ke dalam kode Python. Pendekatan ini menghasilkan tabel *Star Schema* yang sangat bersih dan terstruktur di dalam SQLite. Namun, kekurangannya adalah sifatnya yang kaku, setiap perubahan logika transformasi mengharuskan rekayasa ulang pada kode Python dan pemuatan ulang ke *warehouse*. Sebaliknya, *pipeline* ELT menawarkan fleksibilitas yang jauh lebih tinggi. Karena data mentah langsung dimuat ke *warehouse*, rekayasa fitur seperti teknik *Unpivot* pada kolom komorbiditas dapat dilakukan secara langsung di dalam Power Query. Hal ini memungkinkan analisis untuk memodifikasi struktur pelaporan secara dinamis tanpa menyentuh basis data sumber.

2. **Kinerja dan Beban Komputasi:** Log eksekusi menunjukkan bahwa pendekatan ETL membebani komputasi terberat pada mesin pemrosesan awal (*client-side*). Setelah data masuk ke SQLite, kueri analitik dan *dashboard* berjalan sangat ringan karena data sudah berwujud agregasi akhir. Sebaliknya, pendekatan ELT memindahkan beban komputasi (*compute load*) ke mesin *Business Intelligence*. Penggunaan DAX dan transformasi *on-the-fly* pada Power BI membutuhkan alokasi memori yang lebih besar secara *real-time* saat filter atau *slicer* diaktifkan oleh pengguna.
3. **Konsistensi Data:** Kedua pendekatan berhasil mencapai tingkat konsistensi data yang tinggi berkat penerapan enam aturan validasi. Namun, ETL terbukti lebih andal dalam mencegah masuknya anomali (seperti usia negatif) ke dalam *warehouse* sejak awal (*preventif*), sedangkan ELT lebih bersifat *reaktif*, di mana anomali baru disaring pada lapisan visualisasi.

B. Wawasan Dashboard Business Intelligence

Dashboard analitik yang terhubung langsung dengan *Data Warehouse* berhasil mengungkap beberapa pola kritis terkait perilaku *no-show* pasien. Tampilan antarmuka dari *dashboard* eksekutif interaktif tersebut disajikan pada Fig. 2.




Fig. 2. Tampilan Akhir Dashboard Executive Business Intelligence

- **Distribusi Spasial dan Demografi:** Berdasarkan visualisasi matriks dan *Map*, terdapat disparitas yang jelas pada tingkat kehadiran antar wilayah. Beberapa *Neighbourhood* mencatatkan rasio *no-show* di atas rata-rata region (20,19%). Secara demografis, *Bar Chart* komposisi umur menunjukkan variasi tingkat kepatuhan yang signifikan antara populasi usia produktif dan kelompok lanjut usia.

- **Analisis Tren Waktu dan Operasional:** *Line Chart* yang menampilkan volume pendaftaran berdasarkan hari kerja menunjukkan adanya lonjakan antrean pada hari-hari tertentu. Tingginya angka *lead_time_days* (waktu tunggu antara hari pendaftaran dan hari janji temu) terbukti memiliki korelasi linier dengan peningkatan probabilitas pasien untuk mangkir.
- **Evaluasi Komorbiditas via *Conditional Formatting*:** Implementasi parameter gradasi warna pada visual *Card* memberikan sistem peringatan dini yang efektif. Hasil ekstraksi DAX memperlihatkan perbandingan angka mangkir antara pasien dengan kondisi Hipertensi, Diabetes, Alkoholisme, dan Disabilitas. Pasien dengan penyakit kronis tertentu menunjukkan pola kedisiplinan yang berbeda dibandingkan pasien tanpa komorbiditas, memberikan indikasi bahwa intervensi pengingat harus diprioritaskan pada segmen pasien berisiko tinggi.

IV. KESIMPULAN

Penelitian ini berhasil merancang dan mengimplementasikan arsitektur Big Data berskala besar menggunakan dua *pipeline* independen. Pendekatan ETL menggunakan Python terbukti sangat efektif untuk menghasilkan Data Warehouse dengan skema Star Schema yang terstandarisasi, bersih, dan efisien secara komputasi analitik. Di sisi lain, pendekatan ELT yang memaksimalkan

kapabilitas internal Power BI melalui bahasa SQL, DAX, dan teknik *unpivot* menawarkan fleksibilitas manipulasi visual yang superior tanpa merusak arsitektur data raw.

Secara operasional, *dashboard Business Intelligence* yang dihasilkan mampu memberikan insight multidimensi terkait masalah no-show medis. Temuan spasial, tren fluktuasi waktu, dan korelasi komorbiditas berbasis parameter warna dinamis membuktikan bahwa pendekatan data hibrida ini sangat esensial. Fasilitas kesehatan dapat menggunakan wawasan dari sistem ini untuk mengoptimalkan alokasi tenaga medis, memperbaiki sistem SMS pengingat pasien, dan menerapkan data-driven decision making yang berdampak langsung pada efisiensi rumah sakit.

REFERENCES

- [1] J. Hoppen and Aquarela Advanced Analytics, "Medical Appointment No Shows Dataset," Kaggle, 2016. [Online]. Tersedia: <https://www.kaggle.com/joniarroba/noshowappointments>.
- [2] R. Kimball and M. Ross, *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*, 3rd ed. Indianapolis, IN: Wiley, 2013.
- [3] W. McKinney, "Data Structures for Statistical Computing in Python," dalam *Proceedings of the 9th Python in Science Conference*, Austin, TX, 2010, hal. 51-56.
- [4] T. Erl, W. Khattak, and P. Buhler, *Big Data Fundamentals: Concepts, Drivers & Techniques*. Boston, MA: Prentice Hall, 2016.
- [5] R. Nicole, "Title of paper with only first word capitalized," J. Name Stand. Abbrev., in press.
- [6] Microsoft, "Data Analysis Expressions (DAX) Reference," *Microsoft Learn*, 2024. [Online]. Tersedia: <https://learn.microsoft.com/en-us/dax/>.